

2024년 2학기 산업공학종합설계 최종보고서

적대적 공격(FGSM)을 활용한 Face Detector 교란 기반 Deepfake 방어 가능성 연구

김정현,손상준,최은학

지도 교수 : 이기천 (인)

심사위원 교수 : (인)

한양대학교 산업공학과

0. 초록

본 연구는 **Deepfake** 공격에 대한 방어 가능성을 검증하기 위해, **WIDER FACE** 등 정형화된 데이터셋이 아닌, 사람들이 **SNS** 등 일상에서 올리는 이미지를 활용하여 **Face Detector** 교란 기법의 효과를 분석하고자 한다. 보편화된 적대적 공격 알고리즘인 **FGSM(Fast Gradient Sign Method)** 기반 공격 알고리즘을 사용하여 **MTCNN**, **DSFD**, **S3FD**와 같은 보편적인 **Face Detector**를 공격하였고, 각 공격 기법의 효율성과 방어 성공률을 비교하였다. 방어 가능성의 다양한 분석을 위해 다수의 **Epsilon** 값을 이용하여 이미지로 구성되었으며, 공격 전후 이미지 변화를 시각적으로 비교하여 실험하였다. 실험 결과, 적대적 공격은 **Face Detector**를 일부 경우에서 효과적으로 교란하여 **Deepfake** 방어에 유의미한 성과를 보였으나, 그 외의 경우에선 뚜렷한 방어 효과를 보인다고 보기 어려웠다. 본 연구는 이미지 기반 **Deepfake** 방어 가능성을 확인하고, 향후 연구에서 더 다양한 공격 기법과 **Face Detector**를 탐구할 필요성을 제시한다.

주 용어: **Face Detector**, **Deepfake**, 적대적 공격, **FGSM**, **MTCNN**, **DSFD**, **S3FD**

1. 서론

딥페이크 기술은 인공지능과 딥러닝 기술의 발전으로 탄생한 기술로, 영화, 게임 등 창작 분야에서 활용될 목적으로 개발되었다. 그러나 최근 몇 년간 이 기술은 악의적인 목적에 사용되며 사회적 문제를 야기하고 있다. 특히 딥페이크 기술을 활용한 성범죄는 디지털 성범죄의 새로운 유형으로 자리 잡았으며, 그 심각성이 날로 커지고 있다.

2024년 텔레그램 기반으로 발생한 딥페이크 음란물 유포 사건은 이러한 기술 악용의 대표적인 사례다. 이 사건에서는 텔레그램 채널을 통해 학생과 교원 등 교육계 인사들의 사진이 무단으로 수집되고, 딥페이크 기술을 활용해 음란물로 합성된 뒤 유포되었다. 해당 사건은 사회적 공분을 일으켰으며, 피해자가 전국에 걸쳐 다수 발견됨에 따라 디지털 범죄에 대한 강력한 대응책의 필요성이 대두되었다.

이러한 배경에서 본 연구는 딥페이크 기술을 활용한 공격으로부터 방어하는 새로운 접근법을 제안하고자 한다. 기존 딥페이크 방어 연구는 주로 정형화된 데이터셋을 활용했으나, 본 연구는 사람들이 일상적으로 사용하는 랜덤한 이미지를 통해 딥페이크 방어의 가능성을 검증한다. 특히 본 연구는 **Face Detector(MTCNN, DSFD, S3FD)**를 대상으로 한 적대적 공격(**FGSM**)을 통해 딥페이크 합성을 교란하고, **Deepfake** 생성 도구(**FaceSwap, Roop**)의 활용을 차단하는 방식을 채택하였다.

본 연구는 딥페이크 범죄와 같은 디지털 범죄의 확산을 막기 위한 새로운 기술적 접근법을 제시하며, 특히 일상적인 이미지 데이터가 방어에 활용될 수 있는 가능성을 평가한다. 이를 통해 정책 입안자, 법집행 기관, 기술 개발자는 더욱 신뢰할 수 있는 디지털 범죄 대응 전략을 수립할 수 있을 것으로 기대된다.

2. 관련 연구

Shan et al.(2024)은 Nightshade라는 프롬프트-특화 독성 공격 기법을 통해 생성 모델이 특정 프롬프트에 대해 부정확한 출력을 생성하도록 하는 방법을 제안했다. 이 공격은 기존의 데이터 독성 공격보다 적은 수의 독성 샘플(100개 이하)을 필요로 하며, 독성 샘플은 시각적으로 무해해 보이는 이미지로 설계되어 탐지가 어렵다는 특징이 있다.

Nightshade는 학습 데이터셋에서 특정 개념이 상대적으로 낮은 밀도로 포함되어 있는 '개념 희소성(concept sparsity)' 특성을 악용한다. 이를 통해 공격자는 모델이 특정 프롬프트에 대해 잘못된 개념을 학습하도록 유도할 수 있다. 이 공격은 특정 프롬프트뿐 아니라, 관련된 프롬프트까지 영향을 미치는 'bleed-through' 효과를 보인다. 예를 들어, "dog"에 대한 독성 공격은 "puppy"나 "hound" 같은 연관 개념에도 영향을 미칠 수 있다.

Nightshade는 생성 모델이 부정확한 출력을 생성하도록 교란한다는 점에서 본 연구의 목적처럼 딥페이크 방어에도 사용될 수 있을 것으로 보인다. 하지만 입력으로 이미지만이 필요한 Deepfake 모델들(Image-to-Image)과는 달리, 프롬프트 기반 생성 모델(Text-to-Image)에만 유효한 방식이라는 점에서 그 한계를 지니고 있다.

Li et al.(2023)은 Face Detection 모델을 교란하여 DeepFake 생성의 전처리 과정을 방해하는 새로운 방식의 방어 전략인 Face Poison을 제안한다. 이를 통해 DeepFake 모델이 고품질의 얼굴 데이터를 추출하지 못하도록 하여 최종 합성 결과물의 품질을 저하시킨다. FacePoison은 MTCNN, S3FD, DSFD와 같은 다양한 Face Detector를 목표로 적대적 노이즈를 생성하고, 다중 스케일 특징 방해를 통해 검출 성능을 저하시킨다.

그러나 FacePoison은 특정 Face Detection 모델에 의존하는 구조적 한계를 가지고 있으며, 전이 가능성이 낮아 다양한 DeepFake 생성 도구에 대한 범용적 방어 효과를 보장하지 못할 가능성이 있다. 이에 본 연구는 Face Detection 모델뿐만 아니라 DeepFake 생성 도구 자체의 프로세스를 교란하는 방향으로 확장된 방어 전략을 제안한다. 특히, 사람들이 일상적으로 사용하는 랜덤 이미지를 활용해 DeepFake 방어 효과를 검증하고, FGSM(Fast Gradient Sign

Method)와 같은 효율적인 적대적 공격 방식을 사용하여 범용성을 강화하고자 한다. 이를 통해 본 연구는 FacePoison의 접근법을 확장하면서도 실효성을 높이는 방어 기법을 제시한다.

3. 연구 방법론

1. FGSM 등 적대적 공격 설명 (FGSM, MI-FGSM, NI-FGSM)
2. Face Detector (MTCNN, DSFD, S3FD 설명)
3. FaceSwap, Roop (공격받지 않은 이미지로 스왑했을 때 이미지 예시로 첨부)

3.1 적대적 공격(FGSM, MI-FGSM, NI-FGSM)

본 연구에서는 적대적 공격 기법을 활용하여 Face Detector(MTCNN, DSFD, S3FD)를 교란함으로써 Deepfake 생성 도구(FaceSwap, Roop)의 활용을 방해하고자 하였다. 이를 위해 FGSM(Fast Gradient Sign Method) 및 그 변형 기법인 MI-FGSM(Momentum Iterative FGSM), NI-FGSM(Nesterov Iterative FGSM)을 사용하여 Face Detector의 정확도를 저하시키는 실험을 수행하였다. 각 기법은 공격 강도를 조정할 수 있는 Epsilon값을 바탕으로 다양한 수준의 교란 이미지를 생성하였다. 반복 업데이트를 수행하는 MI-FGSM과 NI-FGSM은 Face Detector가 얼굴 인식에 실패하게 되는 횟수인 5~10번 정도로 유기적으로 진행하였으며, 이는 이미지와 모델, Epsilon별로 상이했기 때문에 특기하지 않는다.

3.1.1 FGSM(Fast Gradient Sign Method)

Goodfellow et al.(2014)가 제안한 FGSM(Fast Gradient Sign Method)은 적대적 공격의 가장 기본적이고 효율적인 방법으로, 입력 데이터에 작은 노이즈를 추가해 딥러닝 모델이 틀린 예측을 하도록 유도하는 기법이다. FGSM은 신경망의 손실 함수의 그래디언트를 기반으로 계산되며, 다음과 같은 수식으로 표현된다

$$x_{adv} = x + \epsilon \times \text{sign}(\nabla_x J(x, y))$$

여기서 x 는 원본 이미지, y 는 정답 레이블, ϵ 은 공격 강도를 나타내는 파라미터, J 는 손실 함수, $\nabla_x J(x, y)$ 는 x 에 대한 손실 함수의 기울기를 의미한다. FGSM은 계산이 간단하고 빠르다는 장점이 있으나, 반복적인 최적화를 수행하지 않아 효과가 제한적일 수 있다. 그럼에도 불구하고

FGSM은 적대적 공격 연구의 기초를 마련한 중요한 기법이며, 딥러닝 모델의 취약성을 분석하거나 적대적 훈련(adversarial training)을 위한 데이터 생성에도 널리 활용되고 있다.

3.1.2 MI-FGSM(Momentum Iterative FGSM)

Dong et al.(2018)가 제안한 **MI-FGSM(Momentum Iterative Fast Gradient Sign Method)**은 **Goodfellow et al.(2014)**의 FGSM의 단점을 보완하기 위해 설계된 적대적 공격 기법으로, 그래디언트 정보를 누적하여 업데이트 방향을 안정화하고 전이 가능성을 높이는 방법이다. MI-FGSM은 신경망의 손실 함수의 그래디언트를 누적하는 모멘텀 기법을 도입하며, 다음과 같은 수식으로 표현된다.

$$g_{t+1} = \mu \times g_t + \frac{\nabla_x J(x_t, y)}{\|\nabla_x J(x_t, y)\|_1}$$

$$x_{t+1} = x_t + \epsilon \times \text{sign}(g_{t+1})$$

여기서 g_t 는 누적된 기울기, μ 는 모멘텀 계수를 나타낸다. MI-FGSM은 FGSM과 달리 그래디언트를 누적하여 지역 최적점(local maxima)에 갇히는 문제를 완화하고, 업데이트 방향의 안정화를 통해 더 높은 전이 가능성을 제공한다. 이로 인해 흰색 상자(white-box) 모델뿐만 아니라 검정색 상자(black-box) 모델에서도 높은 성공률을 보인다.

3.1.3 NI-FGSM(Nesterov Iterative FGSM)

Lin et al.(2020)이 제안한 **NI-FGSM(Nesterov Iterative Fast Gradient Sign Method)**은 **Dong et al.(2018)**의 MI-FGSM을 개선한 적대적 공격 기법으로, Nesterov Accelerated Gradient(NAG)를 도입하여 전이 가능성과 최적화 효율성을 높인 방법이다. NI-FGSM은 그래디언트 정보를 누적하는 모멘텀 기법에 looking ahead 업데이트를 추가하며, 다음과 같은 수식으로 표현된다

$$x_{nest} = x_{adv,t} + \alpha \times \mu \times g_t$$

$$g_{t+1} = \mu \times g_t + \frac{\nabla_x J(x_{nest}, y)}{\|\nabla_x J(x_{nest}, y)\|_1}$$

$$x_{adv,t+1} = Clip_{\epsilon,x} \{x_{adv,t} + \alpha \times sign(g_{t+1})\}$$

g_t 는 누적된 그래디언트, μ 는 모멘텀 계수, x_{nest} 는 looking ahead 업데이트를 통해 계산된 중간 위치, $J(x, y)$ 는 손실 함수를 의미한다.

NI-FGSM은 MI-FGSM과 비교해 그래디언트를 누적하는 동시에 이전 단계에서의 정보를 활용하여 "앞을 내다보는" 특성을 추가한다. 이를 통해 지역 최적점(local maxima)에서 벗어나고, 전이 가능성이 높은 적대적 예제를 생성할 수 있다.

이 방법은 흰색 상자(white-box) 공격뿐만 아니라 검정색 상자(black-box) 공격에서도 높은 성공률을 기록한다. 특히, ImageNet 데이터셋 실험 결과 기존 MI-FGSM 대비 더 높은 공격 성공률과 전이 가능성을 보였다.

3.2 Face Detector

Deepfake 생성 과정에서 Face Detector는 얼굴 영역을 정확히 검출하고 주요 특징점을 추출하는 중요한 전처리 단계로 사용된다. 본 연구는 MTCNN, DSFD, S3FD와 같은 대표적인 Face Detector를 대상으로 실험을 수행하였다. 위 모델들을 선택한 이유는 많은 연구들에서 가장 범용적으로 사용되고 있으며, 현재까지도 다양한 Face Detecting 벤치마크에서 상위권을 차지하고 있기 때문이다. 본 연구에서 사용한 Deepfake 모델의 Face Detector를 그대로 사용하지 않은 이유는 현실 문제에서 활용 가능한지를 검증하기 위한 본 연구의 목표에 있다. 실제 딥페이크 범죄를 일으키는 사람들이 어떠한 모델을 사용하고 어떤 방식으로 접근할 지 알 수 없기 때문에, 전이 가능성을 검증하고자 가장 보편적인 Face Detector들을 선택했다.

3.2.1 MTCNN (Multi-task Cascaded Convolutional Networks)

Zhang et al.(2016)이 제안한 MTCNN(Multi-task Cascaded Convolutional Networks)은 얼굴 검출과 랜드마크 추출을 동시에 수행하는 다중 작업 신경망으로, 얼굴 검출과 랜드마크 추출 간의 상호 연관성을 활용하여 성능을 극대화한 모델이다. 이 신경망은 단계적으로 정교한 결과를 도출하는 세 단계 구조로 구성되어 있다.

MTCNN은 세 단계의 네트워크(P-Net, R-Net, O-Net)로 구성되어 있으며, 각 단계는 얼굴 검출 과정을 점진적으로 정교하게 수행한다. 첫 번째 단계인 P-Net(Proposal Network)은 입력 이미지를 빠르게 처리하여 얼굴 후보 영역을 생성하고, 경계 상자를 조정된 뒤 비최대 억제(non-maximum suppression)를 통해 중복된 후보를 제거한다. 두 번째 단계인 R-Net(Refine Network)은 P-Net에서 생성된 후보를 정제하고, 잘못된 후보를 추가로 제거하며 경계 상자를 재조정한다. 마지막 단계인 O-Net(Output Network)은 최종적으로 얼굴 영역을 검출하고, 5개의 얼굴 랜드마크(눈, 코, 입 위치)를 정확히 출력한다.

MTCNN은 다중 작업 학습 프레임워크를 채택하여 얼굴 검출과 랜드마크 추출을 효율적으로 결합하였으며, 경량화된 구조와 높은 검출 성능 덕분에 실시간 처리에 적합하다. 또한, 학습 과정에서 온라인 하드 샘플 마이닝 기법을 도입하여 어려운 샘플을 효과적으로 학습할 수 있도록 설계되었으며, 이를 통해 검출 성능을 더욱 강화하였다.

이 모델은 얼굴 검출 및 정렬에서 우수한 성능을 보여주지만, 작은 크기의 얼굴 검출이나 조명 변화, 복잡한 배경에서는 상대적으로 취약할 수 있다. 이러한 특성으로 인해 MTCNN은 다양한 얼굴 인식 애플리케이션에서 널리 활용되고 있다.

3.2.2 DSFD (Dual Shot Face Detector)

Li et al.(2019)이 제안한 DSFD(Dual Shot Face Detector)는 얼굴 검출 성능을 향상시키기 위해 두 단계로 구성된 새로운 프레임워크로, 고도화된 특징 학습, 점진적인 손실 설계, 개선된 앵커 매칭과 같은 주요 기법을 결합한 모델이다. DSFD는 VGG16과 ResNet과 같은 강력한 백본을 활용하여 원본 특징 맵을 강화된 특징 맵으로 변환하는 특징 향상 모듈(FEM)을 도입하고, 다양한 스케일의 얼굴을 효과적으로 검출하기 위해 두 단계의 앵커 크기를 사용한 점진적 앵커 손실(PAL)을 설계하였다. 또한, 새로운 앵커 매칭 전략을 통해 앵커와 얼굴 데이터 간의 매칭 성능을 크게 개선하였다.

DSFD는 기존의 단일 단계 감지(single-shot detection) 모델과 비교하여, 작은 얼굴이나 복잡한 배경과 같은 다양한 변수에 더욱 강건한 성능을 보이며, WIDER FACE 및 FDDB와 같은 벤치마크에서 최첨단 성능을 기록하였다. 특히, 두 단계 검출 방식과 보완적인 손실 설계를 통해 검출 정확도뿐만 아니라 모델의 견고성과 유연성을 높였다.

이 모델은 얼굴 검출을 위한 정교한 피라미드 기반 네트워크 설계를 통해 높은 해상도의 위치 정보를 제공하며, 낮은 해상도에서 풍부한 의미 정보를 활용하여 작은 얼굴 검출에서도 우수한 성능을 보인다. DSFD는 대규모 실험을 통해 효과성을 입증했으며, 다양한 환경에서의 얼굴 검출 애플리케이션에 적합하다.

3.2.3 S3FD (Single Shot Scale-invariant Face Detector)

Zhang et al.(2017)이 제안한 **S3FD(Single Shot Scale-invariant Face Detector)**는 다양한 크기의 얼굴을 효과적으로 검출하기 위해 설계된 단일 단계 기반 스케일 불변 얼굴 검출기이다. S3FD는 앵커 기반 검출 프레임워크의 단점을 개선하며, 특히 작은 얼굴 검출에서 뛰어난 성능을 보인다. 이 모델은 다양한 크기의 얼굴이 충분한 특징을 학습할 수 있도록 다양한 크기의 앵커를 여러 계층에 걸쳐 배치하는 스케일 균형 프레임워크를 도입하였다.

S3FD는 세 가지 주요 기법으로 성능을 강화한다. 첫째, 스케일 보상 앵커 매칭 전략을 통해 작은 얼굴 검출의 재현율(recall rate)을 개선하였다. 둘째, 작은 앵커에서 발생하는 높은 오탐율(false positive rate)을 줄이기 위해 최대 선택 배경 레이블(max-out background label)을 도입하였다. 마지막으로, 효과적인 수용 영역(effective receptive field)과 동일 비율 간격 원칙(equal-proportion interval principle)을 기반으로 앵커 크기를 설계하여 다양한 스케일의 얼굴을 정확히 검출할 수 있도록 하였다.

이러한 설계를 통해 S3FD는 WIDER FACE, Fddb와 같은 벤치마크에서 최첨단 성능을 기록하였으며, 특히 어려운 조건의 작은 얼굴 검출에서 강점을 보인다. 또한, 이 모델은 VGA 해상도 이미지 기준으로 초당 36프레임의 속도로 실시간 처리가 가능하며, 다양한 얼굴 검출 애플리케이션에 적합하다.

3.3 Face Swap

본 연구의 주요 목표인 현실 상황과 최대한 비슷한 실험 환경을 세팅하기 위하여 오픈소스 Deepfake 모델들을 활용한 오픈소스 툴을 활용하였으며, 원본 이미지와 교란 이미지에 대해 그 결과를 비교하고자 했다. 본 연구에서 선택한 툴은 Faceswap (<https://faceswap.dev/>) 이다. Faceswap은 오픈소스로 공개되어 있으며, 얼굴이 존재하는 이미지 2장을 입력하면 2장의 얼굴이 서로 바뀐 결과를 출력하는 기능을 갖고 있다.

3.3.1 FaceSwap

FaceSwap은 TensorFlow 및 Keras 프레임워크를 기반으로 동작하며, GPU 가속을 통해 대규모 데이터셋의 학습 시간을 단축시킨다. 얼굴 교체 과정에는 Autoencoder 기반의 모델이 사용되며, 이는 입력된 얼굴의 특징을 학습하고 변환하는 데 핵심적인 역할을 한다.

FaceSwap 툴은 다음과 같은 순서로 작동한다. **Detecting and Align**: 입력된 이미지나 영상에서 얼굴을 자동으로 감지하고 정렬한다. 얼굴 감지에는 MTCNN 또는 DSFD와 같은 다양한 얼굴

감지 모델이 사용될 수 있다. **Training**: 입력된 두 이미지 세트(원본 및 대상)의 얼굴을 기반으로 **Deepfake** 모델을 학습시킨다. **Swap**: 학습된 모델을 바탕으로 대상 얼굴 이미지를 원본 이미지의 얼굴과 교체하여 출력한다. 출력된 결과물은 원본 이미지의 해상도와 비율을 최대한 유지하며, 자연스러운 얼굴 교체가 가능하다. **Postprocessing**: 교체된 얼굴의 품질을 향상시키기 위해 블렌딩, 컬러 매칭 등 다양한 후처리 기술을 적용한다. 결과물은 이미지 또는 영상 포맷으로 저장된다.

4. 실험

4.1 실험 설계

후술할 실험은 GPU A100 80GB, CPU 4 vCore, pytorch 환경에서 진행되었으며, 다음 링크에서 코드 전문을 확인할 수 있다. <https://github.com/Tiabet/IECD> 본 연구에서 진행된 실험의 목표는 현재 존재하는 적대적 공격 알고리즘으로 **Deepfake** 모델을 교란시킬 수 있는가를 검증하는 것에 있다. 이 과정에서 전이 가능성과 현실성을 반영하기 위해 최대한 일반적이고 일상적인 데이터셋을 구축하고자 했으며, 가장 많이 쓰이는 **Face Detector**들을 선택했다. 그러나 초상권 및 접근 제한성 등의 문제로 일반인의 사진은 사용하지 않았으며, 이 점을 보완하고자 유튜브에서 현실성이 높은 영상들을 선택, 연예인 12명(남자 6명, 여자 6명, 각 1000장 이상)의 데이터셋을 구축하였다. 원활한 실험을 위해 모든 이미지는 512*512 크기로 리사이징하였다. 이후 상기한 적대적 공격 알고리즘 3개와 **Face Detector** 3개를 교차 사용하여 공격을 수행하였으며, 원본 이미지와 공격 이미지를 **Deepfake** 모델을 사용했을 때의 결과를 비교하였다. 사용한 **Face Detector** (DSFD, S3FD, MTCNN) 은 추가 훈련을 거치지 않고 공개된 사전 훈련된 가중치를 사용하였으며, 모델 구조 또한 논문 저자들이 공개한 구조 혹은 타이용자가 그에 맞게 구현해놓은 구조를 인용하였다. 현실상황의 **Deepfake** 모델로 채택한 **Faceswap** 툴의 환경은 다음과 같다. **Aligner** - Fan, **Masker** - Custom, **Normalization** - Hist, **Batch Size** - 16, **Iteration** - 100000, **Trainer** - Dlight

본 연구의 주요 목적 중 하나인 전이 가능성 검증은 **Aligner**가 **Fan** 모델을 사용한다는 점으로 검증 가능할 것으로 기대된다. **Faceswap**은 얼굴 감지와는 별개로 얼굴의 주요 특징(landmark)을 특징하는 **Align** 단계를 거치는데, 이는 얼굴을 바꾸고자 하는 두 사람을 더욱 자연스럽게 바꿀 수 있게 해준다. 따라서 **Face Detector**만을 공격해 생성한 교란 이미지가 **Aligner**까지 교란할 수 있다면, **Deepfake** 모델의 훈련 및 추론 단계도 원활하게 교란할 수 있을 것이다.

본 연구에서 진행한 실험에선 현실에서 어떤 **Deepfake** 모델이 범죄에 악용되는지 파악할 수 없었다는 점에서, **Deepfake** 모델이 충분히 훌륭하다는 가정을 충족하고자 **Faceswap**을

Swap을 진행하고자 하는 한 쌍에 대해서 충분히 훈련시키고 사용하였다. 따라서, 훈련된 Faceswap 툴의 모델 체크포인트는 총 6개이다.

4.2 적대적 공격

본 실험에서 비교하고자 하는 실험요인은 총 3가지로, Face Detector의 종류와 적대적 공격 알고리즘의 종류, 공격 세기인 Epsilon의 크기이다. 우선 본 연구에서 사용한 적대적 공격 알고리즘들의 가장 중요한 하이퍼파라미터인 Epsilon을 변화시켜줌으로써 Epsilon의 크기에 따른 효과 차이를 분석하고자 했다. 공격의 세기를 결정하는 하이퍼파라미터인 Epsilon은 클수록 이미지에 더 많은 노이즈를 추가, Deepfake 모델을 더 크게 공격할 수 있다. Figure 1은 DSFD에 대해 FGSM으로 적대적 공격을 실행했을 때 Epsilon 별 노이즈 발생량을 나타낸 예시이다. Musa et al.(2021)의 연구를 참고하여 Epsilon의 크기는 0.01에서 0.05로 제한하였다.




Figure 1. FGSM 메소드로 S3FD를 공격했을 때의 Epsilon별 노이즈 차이

공격한 Face Detector에 따라서도 Deepfake 모델을 교란시킬 수 있는 정도가 다를 수 있을 것이라고 판단하였다. 실제로 공격 Face Detector에 따라서 노이즈가 다르게 생기는 것을 확인할 수 있었다. Figure 2는 DSFD, S3FD, MTCNN에 FGSM 메소드(Epsilon 0.05)로 공격했을 때의 노이즈를 비교한 예시이다. Epsilon이 클수록 특히 노이즈가 뚜렷해지는 것을 확인할 수 있다. 또한 적대적 공격 알고리즘의 종류에 따른 Deepfake 모델 교란 정도를 검증하기 위해 총 3가지의 공격 알고리즘을 사용하였으며, Figure 3은 FGSM, MI-FGSM, NI-FGSM 에 따른 노이즈를 비교한 예시이다. (Epsilon 0.03, 공격 모델 S3FD) FGSM 기반 알고리즘만을 사용하였기 때문에 공격 알고리즘 별 노이즈는 육안으로 비교했을 때는 큰 차이가 없는 것을 알 수 있다.




Figure 2. FGSM 메소드로 공격했을 때의 Face Detector 별 노이즈 차이




Figure 3. S3FD를 Epsilon 0.03으로 공격했을 때 알고리즘 별 노이즈 차이

노이즈가 얼마나 생겼는지를 수치화하기 위하여 **SSIM(Structural Similiarity Index Measure)**을 사용하였다. **SSIM**은 두 이미지의 유사도를 측정할 때 유용하게 사용되는 측정 단위이며, 1에 가까울수록 유사함을 나타낸다. (Wang et al., 2004) Table 1 은 공격 알고리즘과 **Face Detector**, **Epsilon**에 따른 원본 이미지와 교란 이미지의 **SSIM** 점수를 나타낸다. 점수는 데이터로 사용한 총 12명에 대하여 평균을 구한 값이다. **MTCNN**이 모든 알고리즘에 대하여 다른 **Face Detector**보다 높은 **SSIM** 점수를 냈는데, 이는 **MTCNN**의 기울기를 추적, 계산하는 과정에서 얼굴 주변에만 노이즈가 생긴 영향으로 보인다. 또한, **NI-FGSM**과 **MI-FGSM**은 반복 업데이트 도중 얼굴 인식 실패로 업데이트가 중단되는 일이 빈번했기에 엡실론이 더 큰 상황에서도 더 높은 유사도를 띄는 경우가 **MTCNN**에서 확인된다. 추가적으로, 이미지에 적대적 공격을 수행하는 데에는 **DSFD**가 **S3FD**와 **MTCNN**보다 두 배 가량 오래 소요됐으며, 이는 모델의 크기에서 기인한 것으로 해석된다. 또한 반복적인 업데이트를 수행하는 **MI-FGSM**과 **NI-FGSM**이 8~10배 가량 시간이 더 소요되었다. (Figure 5 참조)





Figure 4. 3가지 실험요인 별 SSIM 점수 비교




Figure 5. 공격 알고리즘과 모델 별 이미지 처리 속도 비교

5. 결과

Faceswap의 Aligner인 Fan으로 교란 이미지들의 얼굴 특징들을 Align한 결과, 높은 epsilon을 사용할수록 Aligner가 제대로 작동하지 않았음을 확인할 수 있었다. Figure 6은 Fan의 Aligner 결과를 나타낸다. (Face Detector - S3FD, 공격 알고리즘 - MI-FGSM) 결과로 미루어 보아, Face Detector를 기반으로 생성된 교란 이미지는 최소한 Face Detector 및 Face Aligner까지는 교란에 일부 성공한 것으로 해석된다.




Figure 6. Face Aligner(Fan)으로 교란 이미지 Align 결과

데이터셋에는 총 12명의 연예인들이 있었으며, Deepfake 모델에 적용하기 위해 두 명씩 짝을 지어 총 6쌍(남자 3쌍, 여자 3쌍)의 얼굴에 대해서 Deepfake 모델(Dlight)을 학습시켰다. 이후 추론 과정에서 적대적 공격을 통해 생성된 교란 이미지와 그렇지 않은 원본 이미지와의 결과를

비교하였다. Figure 7 은 원본 이미지와 교란 이미지로 동일 조건에서 추론(Deepfake)을 진행하였을 때의 결과를 비교하는 예시이며, Figure 8은 원본 이미지를 기준으로 Swap을 진행한 결과를 기준으로, 교란 이미지로 Swap을 진행한 결과의 SSIM 점수를 구한 표이다. 낮은 Epsilon에서는 공통적으로 높은 SSIM 점수를 보였으나, Epsilon이 커질수록 SSIM이 낮아지는 경향을 보였다. 특히 Face Detector에서 S3FD와, 적대적 공격 알고리즘에서 FGSM을 사용한 경우에서 더 큰 하락폭을 보였다. 따라서 전이 가능성이 있고 현실 상황에서도 적용 가능하다고 보인다. 또한, Epsilon에 관계 없이 일부 이미지에선 Swap 이후 얼굴이 크게 망가지는 경우들도 있었다. 하지만 일부 경우엔 반대로 Epsilon에 관계 없이 Swap에 성공하는 경우들도 있었으므로, 이는 완벽하게 Deepfake 모델을 교란하는 것이 가능하다고 보이지는 않는다.




Figure 7. 원본 이미지와 교란 이미지의 Deepfake 결과 비교 예시 (NI-FGSM, S3FD, eps 0.05)




Figure 8. 원본 이미지의 Deepfake 결과와 교란 이미지의 Deepfake 결과

6. 결론

실험의 결과, FGSM 기반 적대적 공격을 사용해 Face Detector를 교란하여 생성된 교란 이미지로 Deepfake 모델을 완전히 교란할 수 있다고 확정지을 수는 없으나, 그 가능성은 존재한다고 보인다. 또한, 현실 상황에 바로 적용하기에 딥페이크 범죄 방어 기법이 요구하는 완성성을 불충족하는 것으로 보인다. 교란 강도가 강할수록 Deepfake 모델을 속이는 모습은 보였으나, 노이즈가 너무 심하여 일상생활에서 사용하기 힘든 수준이었기 때문이다.

본 연구는 Deepfake 모델의 공격을 현재 수준의 적대적 공격 알고리즘으로 방어할 수 있는가의 가능성을 검증하고자 했으나, 이후 높은 수준의 방어 기법을 분석하기 위해선 연구의 미흡했던 점을 보완할 필요가 있다.

우선 본 연구에서는 가장 간단한 수준의 적대적 공격 알고리즘인 FGSM과 그 기반 알고리즘 소수를 사용했으나, 최근 많은 연구가 더 좋은 공격 알고리즘을 소개하고 있다. 본 연구의 착안점이 된 FacePoison이 그 예시이다. 또한 객체 탐지 모델 공격 알고리즘들인 NNCO(Neural Network Camouflage Optimization)나 SSOD(Single-Stage Object Detector Attack) 등도 분석해볼 필요가 있다.

또한 본 연구에서 사용한 FaceSwap 툴은 개발된지 시간이 지나서, 최신의 Deepfake 모델을 사용할 수 없었다. 현실에서 어떤 툴로 범죄에 악용되는지 정보를 얻을 수 없었기 때문에 Faceswap을 선택했으나, 원본 이미지에서도 원활하게 Swap이 이루어지지 않은 경우도 있었기 때문에 Deepfake 모델의 한계가 명확했다. Inswapper_128 등의 최신 모델을 사용해서 더 다양한 분석을 할 필요가 있다.

마지막으로, 가능하다면 오픈 소스로 공개된 Deepfake 모델과 얼굴 변환 모델에 직접 공격하여 전이 가능성과 현실성을 분석할 필요가 있다. 본 연구는 Face Detector를 공격함으로써 간접적으로 Deepfake 모델을 공격하였기 때문에, 직접적으로 Deepfake 모델을 공격한다면 더욱 큰 효과를 얻을 수 있을 것으로 기대된다.

7. 참고문헌

Zhang, K., Zhang, Z., Li, Z., & Qiao, Y. (2016). *Joint face detection and alignment using multi-task cascaded convolutional networks*. IEEE Signal Processing Letters, 23(10), 1499-1503. <https://doi.org/10.1109/LSP.2016.2603342>

Li, J., Wang, Y., Wang, C., Tai, Y., Qian, J., Yang, J., Wang, C., Li, J., & Huang, F. (2018). DSFD: Dual Shot Face Detector. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 5055-5064. <https://doi.org/10.48550/arXiv.1810.10220>

Zhang, S., Zhu, X., Lei, Z., Shi, H., Wang, X., & Li, S. (2017). S³FD: Single Shot Scale-Invariant Face Detector. *2017 IEEE International Conference on Computer Vision (ICCV)*, 192-201. <https://doi.org/10.48550/arXiv.1708.05237>

Musa, A., Vishi, K., & Rexha, B. (2021). Attack Analysis of Face Recognition Authentication Systems Using Fast Gradient Sign Method. *Applied Artificial Intelligence*, 35, 1346 - 1360. <https://doi.org/10.1080/08839514.2021.1978149>

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). *Image quality assessment: From error visibility to structural similarity*. IEEE Transactions on Image Processing, 13(4), 600-612. <https://doi.org/10.1109/TIP.2003.819861>

Shan, S., Ding, W., Passananti, J., Zheng, H., & Zhao, B.Y. (2023). Nightshade: Prompt-Specific Poisoning Attacks on Text-to-Image Generative Models. *2024 IEEE Symposium on Security and Privacy (SP)*, 807-825. <https://doi.org/10.48550/arXiv.2310.13828>

Zhu, D., Li, Y., Wu, B., Zhou, J., Wang, Z., & Lyu, S. (2024). Hiding Faces in Plain Sight: Defending DeepFakes by Disrupting Face Detection. <https://doi.org/10.48550/arXiv.2412.01101>

Goodfellow, I.J., Shlens, J., & Szegedy, C. (2014). Explaining and Harnessing Adversarial Examples. *CoRR*, abs/1412.6572. <https://doi.org/10.48550/arXiv.1412.6572>

Dong, Y., Liao, F., Pang, T., Hu, X., & Zhu, J. (2017). Discovering Adversarial Examples with Momentum. *ArXiv*, abs/1710.06081. <https://doi.org/10.48550/arXiv.1710.06081>

Lin, J., Song, C., He, K., Wang, L., & Hopcroft, J.E. (2019). Nesterov Accelerated Gradient and Scale Invariance for Adversarial Attacks. <https://doi.org/10.48550/arXiv.1908.06281>

Face Detector Original Code

DSFD : <https://github.com/hukkelas/DSFD-Pytorch-Inference>

S3FD : https://github.com/rosaj/face_detection?tab=readme-ov-file

MTCNN : <https://github.com/timesler/facenet-pytorch>